



UNIT 0x08

NORMALFORMEN II

KANONISCHE ÜBERDECKUNG

Motivation/Erinnerung

Aufgabe

- Entwicklung einer 'guten' Datenbank [...] u.a. minimal, redundanzfrei [...]

Vorgehen

- Konzeptueller Entwurf [...] ER-Modells ✓
- Überführung in eine 'gute' Datenbank [...] dazu benötigen wir:
 - Implementationsentwurf [...] → Relationales Modell ✓
 - Mathematisches Modell [...] → Relationale Algebra ✓
 - Gütemaß → Normalformen
 - ✦ Kanonische Überdeckung (funktionale Abhängigkeiten ✓, Attributhülle ✓),
 - ✦ Synthesealgorithmus,
 - ✦ Dekompositionsalgorithmus

Äquivalente Menge funktionaler Abhängigkeiten

Motivation

- Gegeben sei ein Schema $R=\{A,B,C,D\}$ mit $FD=\{ A \rightarrow B, B \rightarrow C, AB \rightarrow CD \}$

Kann man die FDs 'vereinfachen'?

- 'vereinfachen' bedeuten i.d.R., so viel wie möglich zu streichen, ohne die Bedeutung zu ändern bzw. hier einen 'äquivalenten' ('so gut wie') Ausdruck mit *weniger* oder *'kleineren'* funktionalen Abhängigkeiten zu erhalten. 'kleiner' bedeutet wiederum, Attribute auf den *rechten und linken Seiten* der funkt. Abhängigkeiten weglassen zu können → Rechts- und Linksreduktion (folgen).
- Hier: Da $A \rightarrow B$ gilt, ist $AB \rightarrow CD$ 'so gut wie' $A \rightarrow CD$, und daher $FD'=\{ A \rightarrow B, B \rightarrow C, A \rightarrow CD \}$ 'äquivalent' zu obiger Menge FDs.

Q&A

- Wie formal konkretisieren?

Äquivalente Menge funktionaler Abhängigkeiten

Definition

- Zu einem Schema R und einer Menge FD funktionaler Abhängigkeiten bezeichne
 - ♦ **FD^+**
die Menge aller funktionalen Abhängigkeiten, die von FD impliziert werden.
- Anstatt die Armstrong-Axiome zu bemühen, überlege man sich, dass gilt
 - ♦ $\alpha \rightarrow \beta \in FD^+$ genau dann, wenn $\beta \subseteq \text{AttrHülle}(FD, \alpha)$.
- Zwei Mengen funktionaler Abhängigkeiten FD_1 und FD_2 heißen **äquivalent**, falls
 - ♦ $FD_1^+ = FD_2^+$, in Zeichen $FD_1 \equiv FD_2$.
- Die kanonische Überdeckung ist in einem gewissen Sinne eine *minimale äquivalente* Menge funktionaler Abhängigkeiten (Definition folgt).
- Technisch: Manchmal schreiben wir auch etwas ungenau $\beta \in \text{AttrHülle}(FD, \alpha)$.

Äquivalente Menge funktionaler Abhängigkeiten

Beispiel FD^+

- Geg. sei Schema $R=\{A, B, C, D\}$, $FD=\{A \rightarrow B, B \rightarrow C, AB \rightarrow CD\}$, dann ist
 - $FD^+=\{A \rightarrow ABCD, B \rightarrow BC, C \rightarrow C, D \rightarrow D, AB \rightarrow ABCD, AC \rightarrow ABCD, AD \rightarrow ABCD, BC \rightarrow BC, BD \rightarrow BD, CD \rightarrow CD, ABC \rightarrow ABCD, ABD \rightarrow ABCD, BCD \rightarrow BCD, ABCD \rightarrow ABCD\}$
(hier sind $A \rightarrow B$ und $A \rightarrow C$ zu $A \rightarrow BC$ etc. zusammengefasst).
- Spaltet man die nicht-trivialen Abhängigkeiten ab, ergeben sich die Darstellungen
 - $FD^+=\{A \rightarrow BCD, B \rightarrow C\} \cup \{\text{triviale Abhängigkeiten}\}$, bzw.
 - $FD^+=\{A \rightarrow BD, B \rightarrow C\} \cup \{\text{triviale Abhängigkeiten}\} \cup \{\text{transitive Abhängigkeiten}\}$.
- FD^+ ergibt sich, per Definition, durch die Betrachtung aller Attributhüllen bzw. der Vereinigung der dazugehörigen Abhängigkeiten.

Q&A

- Wie sieht wohl eine kleinste, äquivalente Menge aus...?

Äquivalente Menge funktionaler Abhängigkeiten

Beispiel Äquivalenz

- Geg. sei Schema $R=\{A, B, C, D\}$, $FD=\{A \rightarrow B, B \rightarrow C, AB \rightarrow CD\}$, dann ist
 - $FD'=\{A \rightarrow B, B \rightarrow C, A \rightarrow CD\}$ äquivalent zu FD , da gilt $FD'^+=FD^+$ (nachrechnen), oder aber durch Betrachtung der im Vergleich *relevanten* Attributhüllen, also hier
 - ♦ $CD \subseteq \text{AttrHülle}(FD, AB)$, und
 - ♦ $CD \subseteq \text{AttrHülle}(FD', A)$.
- *Anders ausgedrückt*: Da die Attributhüllen in beiden Fällen gleich sind, sind auch die funktionalen Abhängigkeiten, die sich einmal aus $AB \rightarrow CD$ und einmal aus $A \rightarrow CD$ ergeben, dieselben. Die restlichen funktionalen Abhängigkeiten sind unberührt, also gilt wiederum $FD'^+=FD^+$.
- *Generell*: Wenn wir Attribute weglassen, so untersuchen wir eine Menge FD' , primär gegeben durch $FD' = FD \setminus \{\text{untersuchte funkt. Abh.}\} \cup \{\text{modifizierte funkt. Abh.}\}$.

Äquivalente Menge funktionaler Abhängigkeiten

Äquivalente Minimierung

- Wir möchten eine 'kleinere' aber äquivalente Menge mit weniger Attributen finden.
D.h. wir versuchen, Attribute wegzulassen und sehen, ob das, was übrig bleibt, äquivalent ist. Das kann man für die rechten und linken Seiten machen.
- Geg. sei Schema $R=\{A, B, C, D\}$, $FD=\{A \rightarrow B, B \rightarrow C, AB \rightarrow CD\}$. Wir starten *links* und betrachten nur die funktionalen Abhängigkeiten, wo wir links auch Attribute weglassen können. Folglich untersuchen wir, ob wir $AB \rightarrow CD$ durch $A \rightarrow CD$ oder $B \rightarrow CD$ ersetzen können. Es ergibt sich *mit der Argumentation von zuvor*:
 - $\{A \rightarrow B, B \rightarrow C, A \rightarrow CD\}$ äquivalent zu FD , da $CD \subseteq \text{AttrHülle}(FD, A)$.
 - $\{A \rightarrow B, B \rightarrow C, B \rightarrow CD\}$ nicht äquivalent zu FD , da: $CD \not\subseteq \text{AttrHülle}(FD, B) = BC$.

Da wir links Attribute weggelassen haben, ist es eine Linksreduktion.



In den Überlegungen haben wir in der Attributhülle das zweite Argument variiert.

Äquivalente Menge funktionaler Abhängigkeiten

Äquivalente Minimierung

- Geg. sei das reduzierte Schema $R=\{A, B, C, D\}$, $FD=\{A \rightarrow B, B \rightarrow C, A \rightarrow CD\}$. Wir testen nun Attribute auf der *rechten* Seite. Folglich untersuchen wir u.a., ob wir $A \rightarrow CD$ durch $A \rightarrow C$ oder $A \rightarrow D$ äquivalent ersetzen können.

- $FD'=\{A \rightarrow B, B \rightarrow C, A \rightarrow D\}$ ist *äquivalent* zu FD , da $C \subseteq \text{AttrHülle}(FD', A)$.

Wir folgern also C aus den *anderen* funktionalen Abhängigkeiten und können es somit hier rechts auch weglassen.

- $FD''=\{A \rightarrow B, B \rightarrow C, A \rightarrow C\}$ ist *nicht äquivalent* zu FD , da $D \notin \text{AttrHülle}(FD'', A)$.

Wir können hier D *nicht* aus den *anderen* funktionalen Abhängigkeiten folgern und es somit auch hier rechts nicht weglassen.

Da wir rechts Attribute weggelassen haben, ist es eine Rechtsreduktion.



In den Überlegungen haben wir in der Attributhülle das erste Argument variiert.

Äquivalente Menge funktionaler Abhängigkeiten

Äquivalente Minimierung

- Das ursprüngliche Schema $R=\{A, B, C, D\}$, $FD=\{ A\rightarrow B, B\rightarrow C, AB\rightarrow CD \}$ haben wir durch *Links- und Rechtsreduktion* in eine äquivalente und kürzere Darstellung
 - $\{ A\rightarrow B, B\rightarrow C, A\rightarrow D \}$überführt.
- Fasst man die funktionalen Abhängigkeiten noch zusammen (Vereinigung), ergibt sich die **kanonische Überdeckung**:
 - $\{ A\rightarrow BD, B\rightarrow C \}$. (vgl. Frage zu Beginn)
- In dem Beispiel haben wir nur einzelne funktionale Abhängigkeiten von FD betrachtet. Allgemein muss man bei der kanonischen Überdeckung *alle* betrachten.

Kanonischen Überdeckung

Definition

- Zu einem Schema R und einer Menge FD funktionaler Abhängigkeiten bezeichne

♦ **FD^C**

die **kanonischen Überdeckung** von FD, falls folgende Kriterien erfüllt sind:

- $FD^C \equiv FD$, d.h. $FD^{C+} = FD^+$.
- Alle $\alpha \rightarrow \beta \in FD^C$ sind minimal in dem Sinne, dass
 - $\forall a \in \alpha$ gilt: $FD^C \setminus (\alpha \rightarrow \beta) \cup (\alpha - a \rightarrow \beta) \neq FD^C$
 - $\forall b \in \beta$ gilt: $FD^C \setminus (\alpha \rightarrow \beta) \cup (\alpha \rightarrow \beta - b) \neq FD^C$
- alle linken Seiten kommen nur einmal vor (einzigartig, Vereinigungsregel).

Algorithmus zur Berechnung der Kanonischen Überdeckung

Berechnung der kanonischen Überdeckung FD^c

- Gegeben sind ein Schema R und einer Menge FD funktionaler Abhängigkeiten.
- **Linksreduktion:** Für alle $\alpha \rightarrow \beta \in FD$ überprüfe, ob ein $a \in \alpha$ überflüssig ist, d.h. ob
 - $\beta \subseteq \text{AttrHülle}(FD, \alpha - a)$.

gilt. In diesem Fall wird $\alpha \rightarrow \beta$ durch $\alpha - a \rightarrow \beta$ in FD ersetzt.

- **Rechtsreduktion:** Für alle $\alpha \rightarrow \beta \in FD$ überprüfe, ob ein $b \in \beta$ überflüssig ist, d.h. ob
 - $\beta \subseteq \text{AttrHülle}(FD \setminus \{\alpha \rightarrow \beta\} \cup \{\alpha \rightarrow \beta - b\}, \alpha)$

gilt. In diesem Fall wird ebenfalls $\alpha \rightarrow \beta$ durch $\alpha \rightarrow \beta - b$ in FD ersetzt.

- **Entfernung** mglw. entstandener $\alpha \rightarrow \emptyset$.
- **Vereinigung** mglw. entstandener $\alpha \rightarrow \beta_1$ und $\alpha \rightarrow \beta_2$ zu $\alpha \rightarrow \beta_1 \beta_2$ (Vereinigung).

Algorithmus zur Berechnung der Kanonischen Überdeckung

Ein erstes Beispiel...

- $R = \{A, B, C, D, E, F\}$,
 $FD = \{ABC \rightarrow DEF, A \rightarrow BC, D \rightarrow EF\}$
- *Vorgehen:*
 - erst Links- dann Rechtsreduktion
 - jeweils Attribute weglassen und 'stur' die Bedingungen testen

B Beispiel: Kanonische Überdeckung

$F = \{ABC \rightarrow DEF, A \rightarrow BC, D \rightarrow EF\}$

Linksreduktion

- **$ABC \rightarrow DEF$**

- **A** überflüssig? **Nein**, denn **AttrHülle**(F, BC): {BC}.
- **B** überflüssig? **Ja**, denn **AttrHülle**(F, AC): {AC} \rightarrow {ABC} \rightarrow {ABCDEF}
– Erhalte $F = \{AC \rightarrow DEF, A \rightarrow BC, D \rightarrow EF\}$

$A \rightarrow BC$

$ABC \rightarrow DEF$
- **C** überflüssig? **Ja**, denn **AttrHülle**(F, A): {A} \rightarrow {ABC} \rightarrow {ABCDEF}
– Erhalte $F = \{A \rightarrow DEF, A \rightarrow BC, D \rightarrow EF\}$

$A \rightarrow BC$

$ABC \rightarrow DEF$

nicht verwechseln:
Attribut F und Menge FD

gleiche
Menge FD,
veränderte
Attribute

neu, aber
äquivalent

Algorithmus zur Berechnung der Kanonischen Überdeckung

Ein erstes Beispiel...

- $R = \{A, B, C, D, E, F\}$,
 $FD = \{ABC \rightarrow DEF, A \rightarrow BC, D \rightarrow EF\}$
- $FD^C = \{A \rightarrow BCD, D \rightarrow EF\}$

B Beispiel: Kanonische Überdeckung

$F = \{A \rightarrow DEF, A \rightarrow BC, D \rightarrow EF\}$

Rechtsreduktion

- **$A \rightarrow DEF$**

- **D** überflüssig? **Nein**, denn
 $\text{AttrHülle}(\{A \rightarrow EF, A \rightarrow BC, D \rightarrow EF\}, A): \{A\} \rightarrow \{AEF\} \rightarrow \{AEFBC\}$
- **E** überflüssig? **Ja**, denn
 $\text{AttrHülle}(\{A \rightarrow DF, A \rightarrow BC, D \rightarrow EF\}, A): \{A\} \rightarrow \{ADF\} \rightarrow \{ADFBC\} \rightarrow \{ADFBCE\}$
– Erhalte $F = \{A \rightarrow DF, A \rightarrow BC, D \rightarrow EF\}$
- **F** überflüssig? **Ja**, denn
 $\text{AttrHülle}(\{A \rightarrow D, A \rightarrow BC, D \rightarrow EF\}, A): \{A\} \rightarrow \{AD\} \rightarrow \{ADBC\} \rightarrow \{ADBCEF\}$
– Erhalte $F = \{A \rightarrow D, A \rightarrow BC, D \rightarrow EF\}$

Die anderen Regeln lassen sich nicht reduzieren

Es ergibt sich: $F^C = \{A \rightarrow BCD, D \rightarrow EF\}$

**veränderte
Menge FD,
gleiche
Attribute**

Algorithmus zur Berechnung der Kanonischen Überdeckung

Anmerkungen Teil I

- **Linksreduktion:** Hier sind nur die funktionalen Abhängigkeiten zu überprüfen, die rechts mind. *zwei Attribute* besitzen, denn eine Abhängigkeit der Form $\emptyset \rightarrow \beta$ (ein weggelassenes Attribut bei nur einem Attribut) macht keinen Sinn.
- **Rechtsreduktion:** Hier sind *alle* funktionalen Abhängigkeiten, auch $\alpha \rightarrow b$ mit nur einem Attribut b rechts, zu überprüfen. Die veränderte Menge für die Attributhülle sieht dann formal so aus: $FD \setminus \{\alpha \rightarrow b\} \cup \{\alpha \rightarrow \emptyset\}$...

Wenn aber in der letzten funktionalen Abhängigkeit nichts aus α folgt, kann man diese Abhängigkeit auch direkt weglassen. Also insgesamt heisst das, man überprüft direkt ohne diese Abhängigkeit die Menge $FD \setminus \{\alpha \rightarrow b\}$.

Wenn dann $\beta=b$ aus α folgt und man die funktionale Abhängigkeit $\alpha \rightarrow b$ direkt weglässt, dann entstehen erst gar keine Abhängigkeiten der Form $\alpha \rightarrow \emptyset$.

Algorithmus zur Berechnung der Kanonischen Überdeckung

Anmerkungen Teil II

- **Rechtsreduktion:** Man beachte, dass beispielsweise die Mengen

- ♦ $FD = \{ \alpha \rightarrow \beta, A \rightarrow BC \}$ und $FD' = \{ \alpha \rightarrow \beta, A \rightarrow B, A \rightarrow C \}$

offensichtlich äquivalent sind und daher die Rechtsreduktion generell etwas abgeändert werden kann (persönlicher Stil):

- Anstatt FD zu modifizieren und $A \rightarrow BC$ erst durch $A \rightarrow C$ (Test, ob B notwendig) und dann durch $A \rightarrow B$ (Test C) zu ersetzen, kann man auch zunächst FD zu einer äquivalenten Menge FD' ändern, in der alle funktionalen Abhängigkeiten mit mehr als einem Attribut auf der rechten Seite aufgespalten werden (Dekomposition).
- Das führt zu einer größeren Menge FD' , die es zu untersuchen gilt, aber insgesamt bleibt die Menge der Tests mit der Attributhülle gleich und jeder einzelne Test ist etwas weniger komplex, weil man die untersuchte funktionale Abhängigkeit nicht modifiziert, sondern weglässt. Im letzten Schritt werden alle wieder vereinigt.

Algorithmus zur Berechnung der Kanonischen Überdeckung

Anmerkungen Teil III

- **Beispiel Rechtsreduktion:** Die Alternativen sind
 - ♦ $FD = \{ \alpha \rightarrow \beta, A \rightarrow BC \}$ und $FD' = \{ \alpha \rightarrow \beta, A \rightarrow B, A \rightarrow C \}$

Klassisch würde man u.a. untersuchen, ob $\beta \subseteq \text{AttrHülle}(FD \setminus \{ \alpha \rightarrow \beta \} \cup \{ \alpha \rightarrow \beta - b \}, \alpha)$ gilt, d.h.

- $B \subseteq \text{AttrHülle}(FD \setminus \{ A \rightarrow BC \} \cup \{ A \rightarrow C \}, A)$?
 $C \subseteq \text{AttrHülle}(FD \setminus \{ A \rightarrow BC \} \cup \{ A \rightarrow B \}, A)$?

In der anderen Variante untersucht man u.a.

- $C \subseteq \text{AttrHülle}(FD' \setminus \{ A \rightarrow B \}, A)$?
- $B \subseteq \text{AttrHülle}(FD' \setminus \{ A \rightarrow C \}, A)$?

**Zunächst (FD') größer, aber
Modifikation ist einfacher.**



Q&A

- Ist die kanonische Überdeckung eindeutig?

Algorithmus zur Berechnung der Kanonischen Überdeckung

Beispiel

- $R = \{ A, B, C, D \}$,
 $FD = \{ A \rightarrow B,$
 $BD \rightarrow C,$
 $ABC \rightarrow AB \}$

Link red.
 $a \rightarrow b$
 $bd \rightarrow c$

$a \rightarrow b$
 $ABC \rightarrow AB$

Attr. Hülle $(\overline{FD}, D) = D$

Attr. Hülle $(\overline{FD}, B) = B$

$C \in \{D\}$ Nein \downarrow

$C \in \{B\}$ Nein \downarrow

Attr. Hülle $(\overline{FD}, BC) = BC$

Attr. Hülle $(\overline{FD}, AC) = ACB$

$AB \in \{BC\}$ \downarrow

$AB \in \{ACB\}$ \checkmark

also B überfl.

$\overline{FD} = \{ A \rightarrow B, BD \rightarrow C, AC \rightarrow AB \}$

Attr. Hülle $(\overline{FD}, A) = AB$ \checkmark

also C überfl.

$\overline{FD} = \{ A \rightarrow B, BD \rightarrow C, A \rightarrow AB \}$

Algorithmus zur Berechnung der Kanonischen Überdeckung

Beispiel

- $R = \{A, B, C, D\}$,
 $FDC = \{A \rightarrow B, BD \rightarrow C\}$

Ausgangspunkt.

$A \rightarrow B$
 $A \rightarrow B$

Attr. Hülle $(\{BD \rightarrow C, A \rightarrow AB\}, A) = AB$
 $B \in \{AB\}$

also B überfl.

$FD = \{A \rightarrow \emptyset, BD \rightarrow C, A \rightarrow AB\}$
 \uparrow
 weglassen

$A \rightarrow B$
 $BD \rightarrow C$

Attr. Hülle $(\{A \rightarrow AB\}, BD) = BD$, $C \in \{BD\} \nrightarrow$

$A \rightarrow B$
 $A \rightarrow AB$

Attr. Hülle $(\{BD \rightarrow C, A \rightarrow B\}, A) = AB$, $AB \in \{AB\}$
 also A überfl.

$FD = \{BD \rightarrow C, A \rightarrow B\}$

$A \rightarrow B$
 $A \rightarrow B$

Attr. Hülle $(\{BD \rightarrow C\}, A) = A$, $B \in \{A\} \nrightarrow$

Kanonische Überdeckung

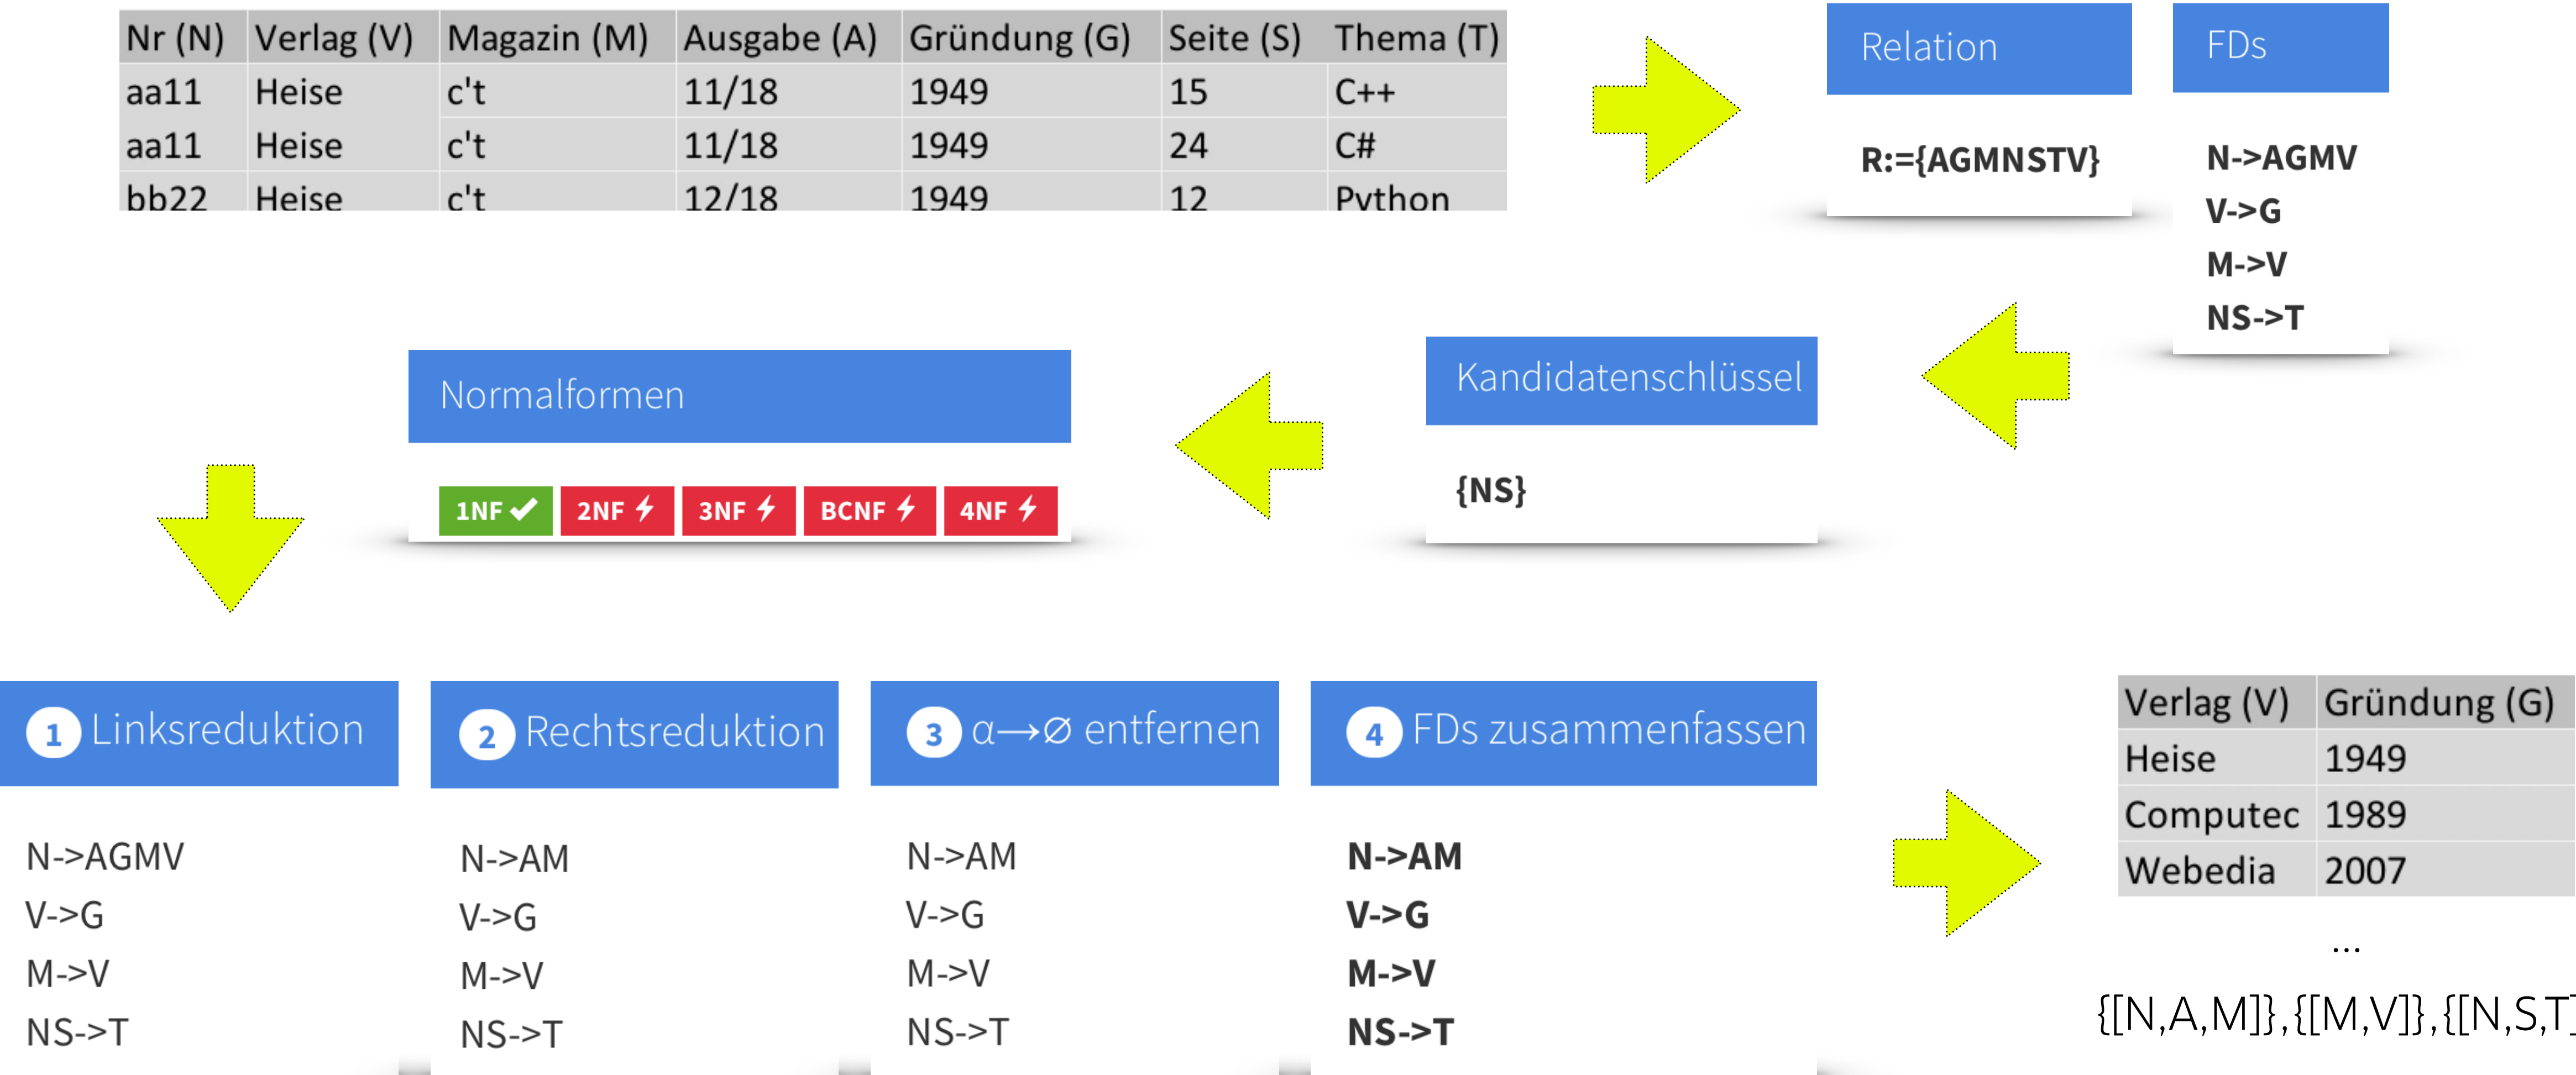
Roter Faden – Wozu das alles?

- Die Kanonische Überdeckung ist der Hauptbestandteil des *Synthesealgorithmus*, der eine Relation in die sogenannte *dritte Normalform* (Gütekriterium) überführt.
- Relationen, die einer gewissen Normalform entsprechen, vermeiden bestimmte Anomalien.
- Anomalien bezeichnen Zustände in der Datenbank, bei denen Daten falsch bzw. inkonsistent sind, z.B. ermöglicht durch Redundanzen (Beispiel 'Heise' vs. 'Heihse').

Was folgt:

- *Teaser*: Artikeldatenbank inkl. Synthesealgorithmus und Normalformen
- *Unit 0x09*: Normalformen, Anomalien, Synthese- und Dekompositionsalgorithmus

Beispiel Kanonische Überdeckung / Synthesealgorithmus



Kanonische Überdeckung / Hauptteil Synthesealgorithmus

Vorschau

Synthesealgorithmus

- Gegeben sind ein Schema R und einer Menge FD funktionaler Abhängigkeiten.
 1. Bestimme Kanonische Überdeckung FD^C zu FD , d.h.
 - Links- und Rechtsreduktion, Entfernung, Zusammenfassung
 2. Für alle $\alpha \rightarrow \beta \in FD^C$ wird Schema $R_k = \alpha \cup \beta$, bzw. Relation $\{[\alpha, \beta]\}$, erzeugt. Die funktionalen Abhängigkeiten, die Attribute aus R_k enthalten, werden R_k zugeordnet.
 3. *Ein* Schlüsselkandidat muss in den R_k aus Schritt 2 enthalten sein. Ansonsten wird eine Relation, die die Attribute eines Schlüsselkandidat enthält, zusätzlich erzeugt.
 4. Einzelne R_k aus Schritt 2 können andere R_m enthalten. Diese Schemata R_m braucht man dann nicht mehr, denn alle Informationen sind in R_k .



Die funktionalen Abhängigkeiten, geeignet reduziert, bestimmen die Relationen im DBMS.

Vorschau

Normalformen

- Die erste Normalform ist gegeben, wenn es keine zusammengesetzten oder mehrwertigen Attribute gibt.
- Die zweite Normalform ist erfüllt, wenn die erste erfüllt ist und alle nicht-prim Attribute voll funktional abhängig von jedem Schlüsselkandidaten sind.
- Die dritte Normalform liegt vor, wenn die zweite erfüllt ist und jedes nicht-prim Attribut direkt und nicht transitiv von einem Schlüsselkandidaten abhängt.

Anmerkungen

- Beispiele und Anomalien, die verhindert werden, folgen!
- Für die zweite und dritte Normalform benötigen wir die Schlüsselkandidaten.
- Bedingungen beziehen sich auf nicht-prim Attribute. Redundanzen bei prim Attributen sind weiter möglich...